

Московский государственный технический университет им. Н.Э. Баумана
Факультет «Информатика и системы управления»
Кафедра «Системы обработки информации и управления»



Отчет
Лабораторная работа № 4
По курсу «Технологии машинного обучения»

ИСПОЛНИТЕЛЬ:

Группа ИУ5-65Б

Камалов М.Р.

"31" мая 2021 г.

ПРЕПОДАВАТЕЛЬ:

Гапанюк Ю.Е.

"__" _____ 2021 г.

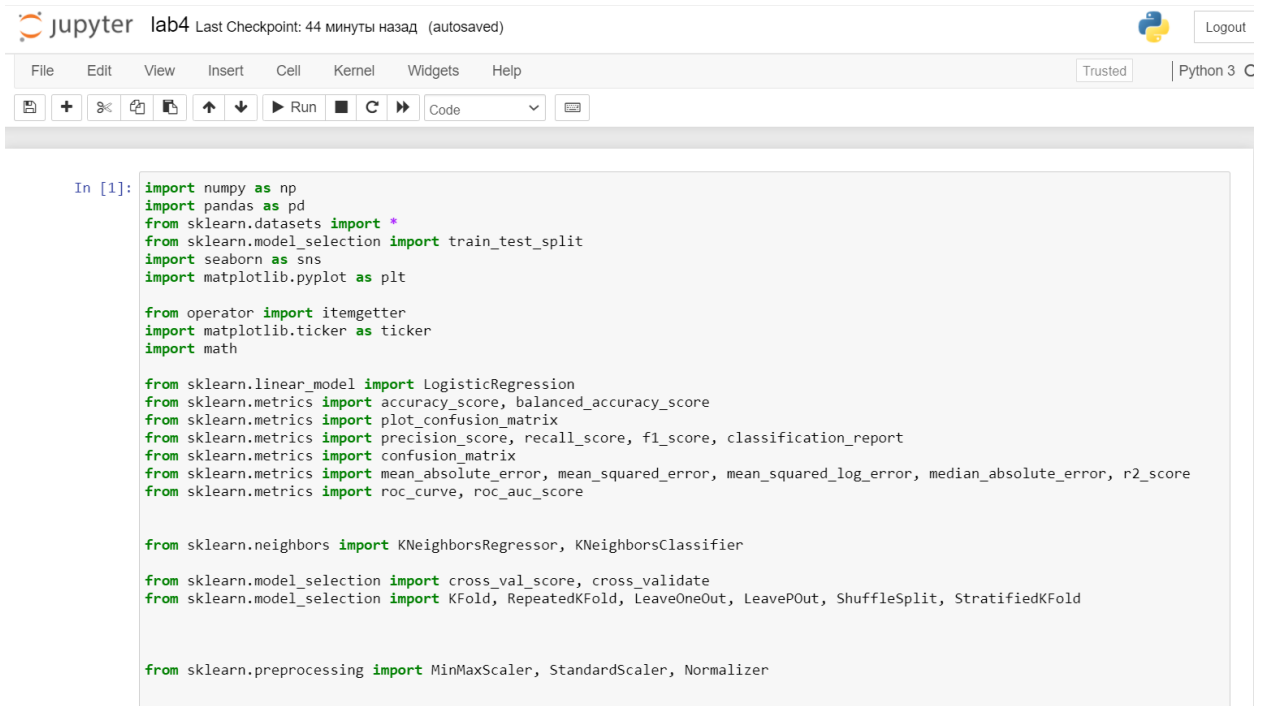
Москва 2021

Цель лабораторной работы: изучение линейных моделей, SVM и деревьев решений.

Задание:

1. Выберите набор данных (датасет) для решения задачи классификации или регрессии.
2. В случае необходимости проведите удаление или заполнение пропусков и кодирование категориальных признаков.
3. С использованием метода `train_test_split` разделите выборку на обучающую и тестовую.
4. Обучите следующие модели:
 - одну из линейных моделей;
 - SVM;
 - дерево решений.
5. Оцените качество моделей с помощью двух подходящих для задачи метрик. Сравните качество полученных моделей.

Скриншоты jupyter notebook



The screenshot shows a Jupyter Notebook interface. At the top, the header includes the Jupyter logo, the text "jupyter lab4", and "Last Checkpoint: 44 минуты назад (autosaved)". On the right, there is a "Logout" button. Below the header is a menu bar with "File", "Edit", "View", "Insert", "Cell", "Kernel", "Widgets", and "Help". To the right of the menu bar are "Trusted" and "Python 3" indicators. Below the menu bar is a toolbar with icons for file operations, running code, and other functions. The main area of the notebook contains a code cell with the following Python code:

```
In [1]: import numpy as np
import pandas as pd
from sklearn.datasets import *
from sklearn.model_selection import train_test_split
import seaborn as sns
import matplotlib.pyplot as plt

from operator import itemgetter
import matplotlib.ticker as ticker
import math

from sklearn.linear_model import LogisticRegression
from sklearn.metrics import accuracy_score, balanced_accuracy_score
from sklearn.metrics import plot_confusion_matrix
from sklearn.metrics import precision_score, recall_score, f1_score, classification_report
from sklearn.metrics import confusion_matrix
from sklearn.metrics import mean_absolute_error, mean_squared_error, mean_squared_log_error, median_absolute_error, r2_score
from sklearn.metrics import roc_curve, roc_auc_score

from sklearn.neighbors import KNeighborsRegressor, KNeighborsClassifier

from sklearn.model_selection import cross_val_score, cross_validate
from sklearn.model_selection import KFold, RepeatedKFold, LeaveOneOut, LeavePOut, ShuffleSplit, StratifiedKFold

from sklearn.preprocessing import MinMaxScaler, StandardScaler, Normalizer
```

```

from sklearn.model_selection import GridSearchCV, RandomizedSearchCV
from sklearn.model_selection import learning_curve, validation_curve

from sklearn.metrics import confusion_matrix
from sklearn.linear_model import LinearRegression
from sklearn.linear_model import SGDRegressor
from sklearn.linear_model import SGDClassifier
from typing import Dict, Tuple
from scipy import stats
from sklearn.svm import SVC, NuSVC, LinearSVC, OneClassSVM, SVR, NuSVR, LinearSVR
from sklearn.tree import DecisionTreeClassifier, DecisionTreeRegressor, export_graphviz

%matplotlib inline
sns.set(style="ticks")

```

Выборка датасета и ее разделение на тестовую и обучающую

```
In [2]: wine = load_wine()
```

```
In [3]: for x in wine:
        print(x)
```

```

data
target
frame
target_names
DESCR
feature_names

```

```
In [4]: # Сформируем DataFrame
wine_df = pd.DataFrame(data= np.c_[wine['data']],
                      columns= wine['feature_names'])
```

```
In [5]: wine_df
```

```
Out[5]:
```

	alcohol	malic_acid	ash	alcalinity_of_ash	magnesium	total_phenols	flavanoids	nonflavanoid_phenols	proanthocyanins	color_intensity	hue	od280/od285
0	14.23	1.71	2.43	15.6	127.0	2.80	3.06	0.28	2.29	5.64	1.04	
1	13.20	1.78	2.14	11.2	100.0	2.65	2.76	0.26	1.28	4.38	1.05	
2	13.16	2.36	2.67	18.6	101.0	2.80	3.24	0.30	2.81	5.68	1.03	
3	14.37	1.95	2.50	16.8	113.0	3.85	3.49	0.24	2.18	7.80	0.86	
4	13.24	2.59	2.87	21.0	118.0	2.80	2.69	0.39	1.82	4.32	1.04	
...
173	13.71	5.65	2.45	20.5	95.0	1.68	0.61	0.52	1.06	7.70	0.64	
174	13.40	3.91	2.48	23.0	102.0	1.80	0.75	0.43	1.41	7.30	0.70	
175	13.27	4.28	2.26	20.0	120.0	1.59	0.69	0.43	1.35	10.20	0.59	
176	13.17	2.59	2.37	20.0	120.0	1.65	0.68	0.53	1.46	9.30	0.60	
177	14.13	4.10	2.74	24.5	96.0	2.05	0.76	0.56	1.35	9.20	0.61	

178 rows × 13 columns

```
In [6]: X_train, X_test, Y_train, Y_test = train_test_split(
        wine.data, wine.target, test_size=0.35, random_state=1)
```

Обучение моделей

Обучение линейной модели

```
In [7]: reg1 = LogisticRegression(max_iter=10000).fit(X_train, Y_train)
```

```
In [8]: target1 = reg1.predict(X_test)
```

```
In [9]: accuracy_score(Y_test, target1), precision_score(Y_test, target1, average='macro')
```

```
Out[9]: (0.9206349206349206, 0.9381499726327313)
```

```
In [10]: Y_test
```

```
Out[10]: array([2, 1, 0, 1, 0, 2, 1, 0, 2, 1, 0, 0, 1, 0, 1, 1, 2, 0, 1, 0, 0, 1,
                2, 1, 0, 2, 0, 0, 0, 2, 1, 2, 2, 0, 1, 1, 1, 1, 1, 0, 0, 1, 2, 0,
                0, 0, 1, 0, 0, 0, 1, 2, 2, 0, 1, 1, 0, 1, 2, 1, 1, 0, 2])
```

```
In [11]: target1
```

```
Out[11]: array([2, 1, 0, 0, 0, 2, 1, 0, 2, 1, 0, 0, 1, 0, 1, 1, 2, 0, 1, 0, 0, 1,
                1, 0, 0, 2, 0, 0, 0, 2, 1, 2, 2, 0, 1, 1, 1, 1, 1, 0, 0, 1, 2, 0,
                0, 0, 0, 0, 0, 1, 2, 2, 0, 1, 0, 0, 1, 2, 1, 1, 0, 2])
```

```
In [12]: def accuracy_score_for_classes(
y_true: np.ndarray,
y_pred: np.ndarray) -> Dict[int, float]:
"""
Вычисление метрики ассигасу для каждого класса
y_true - истинные значения классов
y_pred - предсказанные значения классов
Возвращает словарь: ключ - метка класса,
значение - Ассигасу для данного класса
"""
# Для удобства фильтрации сформируем Pandas DataFrame
d = {'t': y_true, 'p': y_pred}
df = pd.DataFrame(data=d)
# Метки классов
classes = np.unique(y_true)
# Результирующий словарь
res = dict()
# Перебор меток классов
for c in classes:
# отфильтруем данные, которые соответствуют
# текущей метке класса в истинных значениях
temp_data_flt = df[df['t']==c]
# расчет ассигасу для заданной метки класса
temp_acc = accuracy_score(
temp_data_flt['t'].values,
temp_data_flt['p'].values)
# сохранение результата в словарь
res[c] = temp_acc
return res
```

```
def print_accuracy_score_for_classes(
y_true: np.ndarray,
y_pred: np.ndarray):
"""
Вывод метрики ассигасу для каждого класса
"""
accs = accuracy_score_for_classes(y_true, y_pred)
if len(accs)>0:
print('Метка \t Accuracy')
for i in accs:
print('{} \t {}'.format(i, accs[i]))
```

```
In [13]: print_accuracy_score_for_classes(Y_test, target1)
```

```
Метка    Accuracy
0         1.0
1    0.8333333333333334
2    0.9285714285714286
```

Обучение SVM

```
In [16]: model_svc = LinearSVC(C=1.0, max_iter=10000)
model_svc.fit(X_train, Y_train)
target2 = model_svc.predict(X_test)
```

```
C:\Users\User\anaconda3\lib\site-packages\sklearn\svm\_base.py:976: ConvergenceWarning: Liblinear failed to converge, increase
the number of iterations.
warnings.warn("Liblinear failed to converge, increase "
```

```
In [17]: accuracy_score(Y_test, target2), precision_score(Y_test, target2, average='macro')
```

```
Out[17]: (0.9523809523809523, 0.96)
```

```
In [18]: Y_test
```

```
Out[18]: array([2, 1, 0, 1, 0, 2, 1, 0, 2, 1, 0, 0, 1, 0, 1, 1, 2, 0, 1, 0, 0, 1,
2, 1, 0, 2, 0, 0, 0, 2, 1, 2, 2, 0, 1, 1, 1, 1, 1, 0, 0, 1, 2, 0,
0, 0, 1, 0, 0, 0, 1, 2, 2, 0, 1, 1, 0, 1, 2, 1, 1, 0, 2])
```

```
In [19]: target2
```

```
Out[19]: array([2, 1, 0, 1, 0, 2, 1, 0, 2, 1, 0, 1, 1, 0, 1, 1, 2, 0, 1, 0, 0, 1,
1, 1, 0, 2, 0, 0, 0, 2, 1, 2, 2, 0, 1, 1, 1, 1, 1, 0, 0, 1, 2, 0,
0, 0, 1, 0, 0, 0, 1, 2, 2, 0, 1, 0, 0, 1, 2, 1, 1, 0, 2])
```

```
In [20]: print_accuracy_score_for_classes(Y_test, target2)
```

```
Метка    Accuracy
0         0.96
1    0.9583333333333334
2    0.9285714285714286
```

Обучение дерева решений

Классификация

In [21]:

```
def plot_tree_classification(title_param, ds):
    """
    Построение деревьев и вывод графиков для заданного датасета
    """

    n_classes = len(np.unique(ds.target))
    plot_colors = "ryb"
    plot_step = 0.02

    for pairidx, pair in enumerate([[0, 1], [0, 2], [0, 3],
                                    [1, 2], [1, 3], [2, 3]]):
        # We only take the two corresponding features
        X = ds.data[:, pair]
        y = ds.target

        # Train
        clf = DecisionTreeClassifier(random_state=1).fit(X, y)

        plt.title(title_param)

        x_min, x_max = X[:, 0].min() - 1, X[:, 0].max() + 1
        y_min, y_max = X[:, 1].min() - 1, X[:, 1].max() + 1
        xx, yy = np.meshgrid(np.arange(x_min, x_max, plot_step),
                              np.arange(y_min, y_max, plot_step))
        plt.tight_layout(h_pad=0.5, w_pad=0.5, pad=2.5)

        Z = clf.predict(np.c_[xx.ravel(), yy.ravel()])




        Z = Z.reshape(xx.shape)
        cs = plt.contourf(xx, yy, Z, cmap=plt.cm.RdYlBu)




        plt.xlabel(ds.feature_names[pair[0]])
        plt.ylabel(ds.feature_names[pair[1]])

        # Plot the training points
        for i, color in zip(range(n_classes), plot_colors):
            idx = np.where(y == i)
            plt.scatter(X[idx, 0], X[idx, 1], c=color, label=ds.target_names[i],
                        cmap=plt.cm.RdYlBu, edgecolor='black', s=15)

        plt.show()
```

In [22]: plot_tree_classification('Wine dataset', wine)





```
In [23]: clf = DecisionTreeClassifier(random_state=1).fit(X_train, Y_train)
target3 = clf.predict(X_test)
accuracy_score(Y_test, target3), precision_score(Y_test, target3, average='macro')
```

```
Out[23]: (0.9206349206349206, 0.9221256038647342)
```

```
In [24]: Y_test
```

```
Out[24]: array([2, 1, 0, 1, 0, 2, 1, 0, 2, 1, 0, 0, 1, 0, 1, 1, 2, 0, 1, 0, 0, 1,
                2, 1, 0, 2, 0, 0, 0, 2, 1, 2, 2, 0, 1, 1, 1, 1, 1, 0, 0, 1, 2, 0,
                0, 0, 1, 0, 0, 0, 1, 2, 2, 0, 1, 1, 0, 1, 2, 1, 1, 0, 2])
```

```
In [25]: target3
```

```
Out[25]: array([2, 1, 0, 1, 0, 2, 1, 0, 2, 1, 0, 1, 1, 0, 1, 1, 2, 0, 1, 0, 0, 1,
                2, 0, 0, 2, 0, 0, 0, 2, 1, 2, 2, 0, 1, 1, 1, 1, 1, 0, 0, 2, 2, 1,
                0, 0, 1, 0, 0, 0, 1, 2, 2, 0, 1, 1, 0, 1, 2, 1, 0, 0, 2])
```

```
In [26]: print_accuracy_score_for_classes(Y_test, target3)
```

Метка	Accuracy
0	0.92
1	0.875
2	1.0

Итоги

```
In [27]: print('Аккурасу для "Логистической регрессии"', accuracy_score(Y_test, target1))
print('Аккурасу для "SVM"', accuracy_score(Y_test, target2))
print('Аккурасу для "Дерева решений"', accuracy_score(Y_test, target3))
```

```
Аккурасу для "Логистической регрессии" 0.9365079365079365
Аккурасу для "SVM" 0.9523809523809523
Аккурасу для "Дерева решений" 0.9206349206349206
```